

The 4 Fundamental Equations of Backpropagation

Reference Material for MLP Defense (Soutenance)

Multilayer Perceptron Project

8 juin 2026

Table des matières

1	Introduction	2
2	BP1 : Error at the Output Layer	3
3	BP2 : Error at a Hidden Layer	3
4	BP3 : Gradient with respect to Biases	4
5	BP4 : Gradient with respect to Weights	4
6	Gradient Accumulation and Mini-Batch Optimization	5
7	Summary Matrix Dimensions	6

1 Introduction

This document summarizes the four fundamental equations of backpropagation used to train a Multilayer Perceptron from scratch.

Este documento resume las cuatro ecuaciones fundamentales de la retropropagación utilizadas para entrenar un Perceptrón Multicapa desde cero.

Ce document résume les quatre équations fondamentales de la rétropropagation utilisées pour entraîner un Perceptron Multicouche à partir de zéro.

Notation / Notación / Notation

- L : Total loss of the network (e.g., Cross-Entropy or MSE).
- l : Current layer index.
- z^l : Vector of pre-activations at layer l .
- a^l : Vector of activations at layer l ($a^l = \sigma(z^l)$).
- W^l : Weight matrix connecting layer $l - 1$ to layer l .
- b^l : Bias vector at layer l .
- δ^l : Error vector ($\frac{\partial L}{\partial z^l}$).
- $\odot$: Hadamard product (element-wise multiplication).
- m : Size of the mini-batch.

2 BP1 : Error at the Output Layer

Mathematical Formulation

$$\delta^L = \frac{\partial L}{\partial a^L} \odot \sigma'(z^L)$$

Descriptions

English : Computes how much the pre-activations of the output layer affect the final loss. It is the element-wise product of the loss gradient with respect to the output activations and the derivative of the output activation function.

Español : Calcula cuánto afectan las preactivaciones de la capa de salida al coste final. Es el producto elemento a elemento (Hadamard) entre el gradiente del coste respecto a las activaciones de salida y la derivada de la función de activación final.

Français : Calcule l'impact des pré-activations de la couche de sortie sur la fonction de coût finale. C'est le produit terme à terme (produit de Hadamard) entre le gradient du coût par rapport aux activations de sortie et la dérivée de la fonction d'activation de sortie.

3 BP2 : Error at a Hidden Layer

Mathematical Formulation

$$\delta^l = \left((W^{l+1})^T \delta^{l+1} \right) \odot \sigma'(z^l)$$

Descriptions

English : Backpropagates the error from the subsequent layer $l + 1$ to the current hidden layer l . The error vector δ^{l+1} is multiplied by the transposed weight matrix $(W^{l+1})^T$ to project the error backward.

Español : Retropropaga el error desde la capa siguiente $l + 1$ hacia la capa oculta actual l . El vector de error δ^{l+1} se multiplica por la matriz de pesos traspuesta $(W^{l+1})^T$ para proyectar el error hacia atrás.

Français : Rétropropage l'erreur de la couche suivante $l + 1$ vers la couche cachée actuelle l . Le vecteur d'erreur δ^{l+1} est multiplié par la matrice de poids transposée $(W^{l+1})^T$ pour projeter l'erreur en arrière.

4 BP3 : Gradient with respect to Biases

Mathematical Formulation

$$\frac{\partial L}{\partial b^l} = \delta^l$$

Descriptions

English : The gradient of the loss with respect to any bias vector b^l is exactly equal to the error vector δ^l computed for that same layer.

Español : El gradiente del coste respecto a cualquier vector de sesgo b^l es exactamente igual al vector de error δ^l calculado para esa misma capa.

Français : Le gradient de la fonction de coût par rapport à n'importe quel vecteur de biais b^l est exactement égal au vecteur d'erreur δ^l calculé pour cette même couche.

5 BP4 : Gradient with respect to Weights

Mathematical Formulation

$$\frac{\partial L}{\partial W^l} = \delta^l \cdot (a^{l-1})^T$$

Descriptions

English : Computes the partial derivative of the loss with respect to the weights matrix W^l via the outer product of the current layer's error vector δ^l and the transposed activation vector from the previous layer.

Español : Determina la derivada parcial del coste respecto a la matriz de pesos W^l . Se calcula mediante el producto externo entre el vector de error de la capa actual δ^l y el vector de activación traspuesto de la capa anterior.

Français : Détermine la dérivée partielle de la fonction de coût par rapport à la matrice de poids W^l . Elle est calculée via le produit externe entre le vecteur d'erreur de la couche actuelle δ^l et le vecteur d'activation transposé de la couche précédente.

6 Gradient Accumulation and Mini-Batch Optimization

Mathematical Formulation for a Mini-Batch of size m

$$dW^l = \frac{1}{m} \sum_{i=1}^m \delta^{l,(i)} \cdot (a^{l-1,(i)})^T$$
$$db^l = \frac{1}{m} \sum_{i=1}^m \delta^{l,(i)}$$

Descriptions

English : In practical vectorized implementations using mini-batches, the gradients dW^l and db^l are averaged over all m samples in the batch. The matrix dW^l accumulates the outer products of errors and incoming activations a^{l-1} (the data before computing z^l). The vector db^l is the row-wise average of the errors. These averaged gradients are immediately ready to be used by optimization algorithms such as Gradient Descent : $W^l = W^l - \alpha \cdot dW^l$.

Español : En la implementación práctica usando mini-batches, los gradientes dW^l y db^l se promedian sobre las m muestras del lote. La matriz dW^l acumula el producto externo de los errores locales y las activaciones entrantes de la capa anterior a^{l-1} (lo que había antes de calcular z^l). El vector db^l es el promedio por filas de los errores. Estos gradientes promediados quedan listos para algoritmos de optimización como el Descenso de Gradiente : $W^l = W^l - \alpha \cdot dW^l$.

Français : Dans l'implémentation pratique vectorisée par mini-batch, les gradients dW^l et db^l sont moyennés sur l'ensemble des m échantillons du batch. La matrice dW^l accumule le produit externe des erreurs locales et des activations entrantes de la couche précédente a^{l-1} (les données présentes avant le calcul de z^l). Le vecteur db^l est la moyenne des erreurs selon l'axe des échantillons. Ces gradients moyennés sont immédiatement prêts à être utilisés par des algorithmes d'optimisation comme la Descente de Gradient : $W^l = W^l - \alpha \cdot dW^l$.

7 Summary Matrix Dimensions

Variable	Shape (Matrix Dimension for a single sample)
W^l	$(\text{neurons}^l, \text{neurons}^{l-1})$
b^l	$(\text{neurons}^l, 1)$
z^l, a^l, δ^l	$(\text{neurons}^l, 1)$
dW^l	$(\text{neurons}^l, \text{neurons}^{l-1})$
db^l	$(\text{neurons}^l, 1)$